

Proyecto Final Modulo de Machine Learning

Bootcamp Data Science

Jon Olalde Jometon

Agosto de 2025

INTRODUCCIÓN

Caso → Quejas presentadas por distintos consumidores ante la Oficina de Protección Financiera al Consumidor o CFPC



Oficina para la Protección
Financiera del Consumidor

El dataset posibilita el análisis de patrones de comportamiento.

El análisis de estos datos es relevante por:

- Impacto Social y económico.
- Valor empresarial.
- Aplicabilidad técnica.



MARCO TEORÍCO - PRÁCTICO

El proyecto se va a enfocar en los siguientes aspectos:

1. **Análisis Descriptivo de los Datos (EDA):** Con el fin de comprender su estructura de los datos, limpiar y extraer los patrones iniciales.
2. **Construcción de los modelos predictivos:** Se va a proceder a desarrollar 3 modelos, dos de clasificación y uno de regresión, con el fin de responder las siguientes preguntas claves:
 1. ¿El consumidor disputara la respuesta obtenida por parte de la empresa?
 2. ¿La queja será respondida a tiempo o no?
 3. ¿Cuánto de rápido será la queja procesada por la CPFB
3. **Evaluación y comparación de los resultados:** Medir el rendimiento de los diversos modelos en base a sus métricas.

DATASET

El origen del dataset provienen de la plataforma publica del CFPB. consta de 28.156 reclamaciones (filas) y 14 variables, con un periodo temporal cubierto que va desde el 01-01-2015 al 19-03-2015.

Grupo	Variable	Descripción
Identificación y fechas	Complaint ID	Identificador único de la queja.
	Date Recieved	Fecha de recepción del CFPB.
	Date sent to company	Fecha de envió a la Compañía.
Descripción del caso	Product	Tipo de Producto Financiero.
	Sub Product	Categoría especifica dentro del producto.
	Issue	Problema reportado.
	Sub Issue	Detalle adicional del problema.
	State	Estado del consumidor.
	ZIP Code	Código postal del consumidor.
	Company	Entidad Financiera involucrada
Resultados / Estado	Company Response	Tipo de respuesta de la compañía
	Timely response?	¿Respondió en plazo?
	Consumer disputed?	¿Consumidor conforme?

DATASET - Calidad de los datos y distribuciones clave

Aspecto	Variable	Descripción / Distribución
Valores faltantes	Consumer disputed?	78,7% nulos
	Sub-issue	53,1% nulos
	Sub-product	37,6% nulos
	State	1,5% nulos
	ZIP code	0,99% nulos
	Resto	Sin apenas nulos
Distribuciones clave	Timely response?	Yes: 97,5% // No: 2,5%
	Consumer disputed?	Yes: 78,4% / No: 21,6% / Faltantes: 10%
	Company response	Closed w/ explanation: 68,8% / Non-monetary relief: 12,8% / In progress: 9,6% / Monetary relief: 5,4% / Closed: 2,2% / Untimely: 1,3%
	Product (Top 5)	Debt collection: 26,6% / Mortgage: 23,5% / Credit reporting: 20,3% / Credit card: 10,1% / Bank account: 9,3%
	Issue (Top 5)	Incorrect info credit report: 4.170 / Collect debt not owed: 3.351 / Loan modification: 3.049 / Loan servicing: 2.627 / Disclosure verification: 1.300

DATASET - Preparación

Para abordar estos problemas se aplicaron distintas estrategias:

- **Imputación o eliminación** de valores nulos **según la relevancia de la variable**
- **Agrupación o transformación de variables categóricas de alta cardinalidad.**
- **Generación de nuevas variables** a partir de otras (ej. diferencia entre “*Date sent to company*” y “*Date received*” para estimar el tiempo de respuesta).
- **Codificación de variables categóricas.**
- **Balanceo de las clases** debido a la desigualdad entre ellas.

DATASET - Limpieza de los Datos

1. **Eliminación** de la columna auxiliar – *Unnamed:0* - ya que no contiene información relevante
2. **Conversión** de *Date Recieved* y *Date Sent to Company*: a **formato datetime**, para posteriormente **crear** la **variable** *Response_days*.
3. *Consumer disputed?* Con 78,8% de valores nulos, se ha optado por **imputar con “No”** a **casos cerrados** y a **“Pending”** **casos abiertos o con respuesta tardía**.
4. Geografía (*State/ZIP Code*) con aproximadamente 1% nulos, se opta por una **imputación cruzada usando rangos de códigos postales**.
5. *Company*: Presenta 1.534 valores únicos, con una distribución muy sesgada. Por lo que se opta por **normalizar y realizar agrupaciones** de aquellas cuyos **counts** sean **menor de 50**.
6. Variables de producto e incidencia, **imputaciones cruzadas**:
 1. *Product*: 111 categorías → El top concentran mas del 90%
 2. *Sub-product*: imputación por moda según combinación con *Product–Issue*, **resto** como *Unknown*.
 3. *Issue*: 89 categorías, casi completos → **usado como referencia** para imputaciones.
 4. *Sub-issue*: 53% nulos, redundante → **descartado**

MODELO 1 - ¿El consumidor disputara la queja?

Objetivo: Modelo de clasificación multiclase que prediga si un consumidor disputara la queja.

Ventajas: Nos permite entender la percepción del cliente así como anticiparse a posibles conflictos.

Variable Objetivo: Clasificación de quejas en 3 categorías:

- “No”: El consumidor no disputara la queja.
- **“Yes”: El consumidor disputara la queja → Importante desde punto de vista de negocio**
- “Pending”: La disputa aún se encuentran en proceso.

Se evaluará el uso de la variable “*Sub-product*” así como su ausencia.

MODELO 1 - Random Forest

En términos generales observamos que la variable “*Sub-product*” favorece las métricas del modelo.

Modelo	Accuracy	F1 “No”	F1 “Pending”	F1 “Yes”	Recall “Yes”	AUC Score	Observaciones
RF Inicial con subproduct	0,777	0,85	1	0,19	0,15	0,788	Buenas clases mayoritarias, pero “Yes” muy bajo.
RF Inicial sin subproduct	0,761	0,84	1	0,21	0,19	0,7847	Ligera perdida global, mejora mínima en “Yes”.
RF + SMOTE	0,790	0,86	1	0,17	0,13	0,7886	F1 no mejora, SMOTE poco útil.
GridSearch	0,702	0,78	1	0,30	0,38	0,801	Mejor detección de “Yes”. Baja <i>accuracy</i>
GridSearch + SMOTE	0,718	0,80	1	0,29	0,35	0,799	Mejora marginal del modelo anterior

MODELO 1 - XGBoost

Modelo	Accuracy	F1 "No"	F1 "Pending"	F1 "Yes"	Recall "Yes"	AUC Score	Observaciones
XGBoost Baseline	0,835	0,90	1	0,08	0,04	0,81	Excelente para las clases mayoritarias, pero "Yes" no es detectada.
XGBoost ajuste de pesos	0,64	0,71	1	0,34	0,54	0,81	Gran mejora en "Yes" pero con caída fuerte en "No" así como en la exactitud global
XGBoost GridSearch	0,77	0,85	1	0,26	0,23	0,81	F1 no mejora, SMOTE poco útil.
XGBoost GridSearch + SMOTE	0,76	0,84	1	0,26	0,25	0,80	No hay cambios

MODELO 1 - Análisis comparativo

Modelo con **mejor exactitud** global → XGBoost Baseline (0,84)

- Problema: **No identifica** casos de reclamación “Yes” , ya que tiene un *recall* de 0.04

Modelo **mas equilibrado** → XGBoost con *GridSearch*

- Mas **confiable** en términos globales
- Problema: **Sacrifica algo de *recall*** en “Yes”

Modelo que **mejor consigue detectar reclamaciones** → XGBoost con ajuste de pesos

- Eleva el *recall* de “Yes” hasta 0,54 y una F1-Score para esta clase de 0,34
- **Enfoque adecuado si la prioridad es no dejar escapar reclamaciones** incluso a costa de falsos positivos

MODELO 2 - ¿La queja será respondida a tiempo?

Objetivo: Modelo de clasificación binaria que prediga si la queja será respondida a tiempo

Ventajas: **Anticipar el cumplimiento de los tiempos de respuesta**, para mejorar la experiencia del cliente así como la gestión interna de la empresa en cuestión → **Identificar los “No”**

Modelo	Accuracy	F1 “Yes”	F1 “No”	Recall “No”	Macro F1	Macro Recall	ROC Auc	Observaciones
RF Baseline	0,97	0,99	0,50	0,50	0,74	0,74	0,87	Muy buen desempeño global, pero falla en la minoritaria “No”
RF GridSearch + SMOTE	0,98	0,99	0,58	0,46	0,78	0,73	0,88	Mejora de marginal de “No” gracias a SMOTE y hiperparametrización, equilibrando clases
XGBoost GridSearch	0,986	0,99	0,63	0,46	0,81	0,73	0,92	Excelente en mayoritaria, falla algo en la minoritaria
XGBoost – ajuste de pesos	0,64	0,94	0,24	0,67	0,59	0,79	0,90	Mejor detección de “Yes”, sacrifica precisión y <i>recall</i> de no (sobrepredicción)
XGBoost + GridSearch+ SMOTE	0,986	0,99	0,63	0,46	0,81	0,73	0,91	Sin cambios respecto a Baseline

MODELO 2 - Análisis comparativo

Modelo de **Random Forest** → **Fiables para predecir respuestas a tiempo** pero no excepciones

- Buen desempeño en la clase mayoritaria “Yes” pero no detectan bien “No”
- SMOTE → Mejora marginal el *recall* aunque no suficiente

Modelo **mas equilibrado** → XGBoost con *GridSearch*

- Mejor capacidad discriminativa y precisión perfecta en “No”
- **Problema: Recall bajo** en “No” → Se **escapan la mitad** de los retrasos
- SMOTE no mejora

Mejor modelo **desde perspectiva de negocio** → XGBoost con ajuste de pesos

- *Recall* de “No” hasta 0,64 aunque mayor falsos positivos, caída en exactitud global
- **Enfoque adecuado si la prioridad tomar acciones preventivas maxificando la detección de retrasos**

MODELO 3 - ¿En cuántos días será procesada la queja?

Objetivo: Predecir el tiempo medio de procesamiento de la queja (en días) por parte de la CFPC

Ventajas: Nos permite agilizar el tramite de las quejas para el beneficio del consumidor, por medio de una estimación cuantitativa.

PROBLEMA: Se intenta un modelo de regresión lineal, pero debido a la distribución altamente asimétrica de la variable hace que los modelos tiendan a subestimar los casos largos y no capturen la variabilidad real

Modelo	Variable	MAE	RMSE	R ²	Observaciones
Regresion Lineal	Original	3,12	5,18	0,0937	Captura muy poca variabilidad; subestima valores altos; distribución de errores asimétrica
RF Regressor	Original	3,10	5,14	0,1042	Ligera mejora; predicciones concentradas en valores bajos; sigue sin capturar extremos
XGBoost Regressor	Original	2,74	5,45	-0,0048	Mejor MAE, pero RMSE alto; R ² negativo; subestima tiempos largos; sesgo hacia promedio
Regresión Lineal	Logarítmica	2,76	5,49	-0,018	Cambio de escala no mejora; sigue sin explicar variabilidad; subestima extremos
RF Regressor	Logarítmica	2,75	5,48	-0,0137	Mayor flexibilidad no ayuda; errores y R ² similares a la lineal; predicciones concentradas
XGBoost Regressor	Logarítmica	2,74	5,45	-0,0048	No mejora significativamente; sigue sin capturar patrones extremos; limitación por variables disponibles

MODELO 3 – Cambio a modelo de clasificación

Cambio de enfoque: **Cambio a modelo de clasificación multiclase** → Para ello creación de una nueva variable “Delay_class”

Agrupación los tiempo de resolución en **3 clases**

- Quejas procesadas **rápidamente** (0-3 Días)
- Retraso **moderado** (4-14 días)
- Retraso **prolongado** (mas de 14 días)

MODELO 3 – Rendimientos de los modelos

Modelo	Oversampling	Accuracy	F1-Rapida	F1- Moderado	F1- Prolongado	Macro F1	ROC AUC	Observaciones
Random Forest Grid Search	No	0,61	0,73	0,42	0,27	0,47	0,71	Clase mayoritaria acertada; clase minoritaria detectada pero con muchos falsos positivos.
Random Forest Grid search	SMOTE	0,65	0,77	0,40	0,28	0,48	0,71	Apenas hay cambios

Modelo	Accuracy	F1- Rapida	F1- Moderada	F1- Prolongado	Macro F1	ROC AUC	Observaciones
Modelo XGBoost + GridSearch	0,70	0,81	0,34	0,12	0,42	0,705	Modelo sesgado hacia la clase mayoritaria; clase 2 casi no detectada
Modelo XGBoost + GridSearch + Ajuste de pesos	0,58	0,70	0,44	0,25	0,46	0,71	Mayor equilibrio entre clases; clase minoritaria detectada mucho mejor, aunque baja precisión global

MODELO 3 - Análisis comparativo

Modelo de Random Forest → Fiables para predecir la clase mayoritaria (0: respuestas rápidas), pero no excepciones

- SMOTE → Mejora ligeramente el *recall en clase 2*

Modelo **mas equilibrado** → XGBoost con *GridSearch*

- Mejor capacidad discriminativa y precisión solida en “respuestas rápidas”
- Problema: **recall bajo** clases minoritarias
- SMOTE no mejora

Mejor modelo desde **perspectiva de negocio** que → XGBoost con ajuste de pesos

- *Recall* de “2” hasta 0,63 y mejora en clase 1, aunque aumenta falsos positivos y caída en exactitud global
- **Enfoque adecuado si la prioridad es detectar correctamente retrasos y maximizar acciones preventivas.**

CONCLUSIONES

- El Dataset presenta **problemas graves de calidad**, incluyendo valores faltantes, desbalance extremo de clases y poca correlación entre predictores y objetivos, que **condiciona de manera decisiva el rendimiento de los modelos**.
- **Modelo 1: XGBoost base logra alta exactitud** pero no detecta disputas reales, mientras que el **ajuste de pesos mejora la sensibilidad** de la clase “Yes” **a costa de más falsos positivos**, reflejando la **disyuntiva entre precisión global y operatividad enfocada al negocio**.
- **Modelo 2: XGBoost con ajuste de pesos** maximiza el *recall* de respuestas tardías, **generando falsas alarmas**, lo que resulta útil para anticipar problemas de gestión
- **Modelo 3: Los modelos lineales clásicos** presentan un **desempeño muy limitado** por la **baja correlación entre predictores y objetivo**, dado la mala calidad de los datos.
- **Modelo 3:** A nivel de clasificación ninguno resuelve completamente el desbalance en tiempos, aunque **XGBoost con ajuste de pesos** mejora la detección de las clases tardías aunque cae la exactitud, este **enfoque es adecuado si la prioridad es detectar correctamente los retrasos y maximizar acciones preventivas**.
- En definitiva, en problemas de clasificación con datos incompletos y desbalanceados, este tipo de **aproximaciones de sobremuestreo, ajuste de pesos y hiperparametrización son eficaces**, siempre recordando que la calidad del dataset es un factor limitante insalvable. Dado que esto **permiten maximizar la detección de casos críticos, que es de interés para el negocio**, aunque implique asumir un mayor numero de falsas alarmas